

UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ

MURILO EMANOEL SUDARIO RODRIGUES

**UTILIZAÇÃO DE APRENDIZADO DE MÁQUINA PARA PREVISÃO DE DEMANDA
USANDO ANÁLISE DE SENTIMENTO**

PONTA GROSSA

2025

MURILO EMANOEL SUDARIO RODRIGUES

**UTILIZAÇÃO DE APRENDIZADO DE MÁQUINA PARA PREVISÃO DE DEMANDA
USANDO ANÁLISE DE SENTIMENTO**

**Using machine learning for demand forecasting
using sentiment analysis**

Trabalho de conclusão de curso de Graduação
apresentado como requisito para obtenção do título
de Bacharel em Ciência da Computação da
Universidade Tecnológica Federal do Paraná
(UTFPR).

Orientadora: Simone de Almeida

PONTA GROSSA

2025



[4.0 Internacional](https://creativecommons.org/licenses/by/4.0/)

Esta licença permite compartilhamento, remixe, adaptação e criação a partir do trabalho, mesmo para fins comerciais, desde que sejam atribuídos créditos ao(s) autor(es). Conteúdos elaborados por terceiros, citados e referenciados nesta obra não são cobertos pela licença.

MURILO EMANOEL SUDARIO RODRIGUES

**UTILIZAÇÃO DE APRENDIZADO DE MÁQUINA PARA PREVISÃO DE DEMANDA
USANDO ANÁLISE DE SENTIMENTO**

Trabalho de Conclusão de Curso de Graduação
apresentado como requisito para obtenção do título
de Bacharel em Ciência da Computação da
Universidade Tecnológica Federal do Paraná
(UTFPR).

Data de aprovação: 12/Novembro/2024

André Pinz Borges
Doutor
Universidade Tecnológica Federal do Paraná

Helyane Bronoski Borges
Doutora
Universidade Tecnológica Federal do Paraná

Simone de Almeida
Doutora
Universidade Tecnológica Federal do Paraná

**PONTA GROSSA
2025**

Dedico este trabalho à minha família, pelos
momentos de ausência.

AGRADECIMENTOS

Certamente estes parágrafos não irão atender a todas as pessoas que fizeram parte dessa importante fase de minha vida. Portanto, desde já peço desculpas àquelas que não estão presentes entre essas palavras, mas elas podem estar certas que fazem parte do meu pensamento e de minha gratidão.

Agradeço à minha orientadora Professora Simone de Almeida, pela sabedoria com que me guiou nesta trajetória.

Aos meus colegas de sala.

A Secretária do Curso, pela cooperação.

Gostaria de deixar registrado também, o meu reconhecimento à minha família, pois acredito que sem o apoio deles seria muito difícil vencer esse desafio.

Enfim, a todos os que por algum motivo contribuíram para a realização desta pesquisa.

Eu denomino meu campo de Gestão do
Conhecimento, mas você não pode gerenciar
conhecimento. Ninguém pode. O que você pode
fazer, o que a empresa pode fazer é gerenciar o
ambiente que otimize o conhecimento.
(DAVENPORT; PRUSAK, 2012).

RESUMO

A ciência de dados combina disciplinas como computação, estatística e matemática para tratar, analisar e modelar dados com o objetivo de gerar previsões eficazes para decisões estratégicas. Este projeto foca na integração da análise de sentimentos, uma técnica de processamento de linguagem natural (NLP), com modelos de aprendizado de máquina para prever demandas em setores específicos. A análise de sentimentos identifica emoções em textos, mapeando informações subjetivas que podem aprimorar modelos preditivos, apesar dos desafios como ambiguidades linguísticas e dados ruidosos. O estudo propõe o uso de algoritmos como Naive Bayes, Regressão Logística, LSTM e Transformers para classificar sentimentos, integrando-os a modelos preditivos, como séries temporais e aprendizado profundo. A coleta de dados será feita em fontes confiáveis, como redes sociais e sites de avaliações, visando estruturar dados não estruturados. O projeto aplicará essas técnicas em um setor definido para validar seu impacto, contribuindo com novas abordagens na literatura científica para a previsão de demanda.

Palavras-chave: Análise de Sentimentos; Previsão de Demanda; Aprendizado de Máquina; Processamento de Linguagem Natural.

ABSTRACT

Data science combines disciplines such as computing, statistics, and mathematics to process, analyze, and model data with the goal of generating effective predictions for strategic decision-making. This project focuses on integrating sentiment analysis, a natural language processing (NLP) technique, with machine learning models to forecast demand in specific sectors. Sentiment analysis identifies emotions in text, mapping subjective information that enhances predictive models, despite challenges like linguistic ambiguities and noisy data. The study proposes using algorithms such as Naive Bayes, Logistic Regression, LSTM, and Transformers to classify sentiments, integrating them into predictive models like time series and deep learning. Data will be collected from reliable sources such as social media and review websites to structure unstructured information. The project will apply these techniques to a defined sector to validate its impact, contributing new approaches to the scientific literature on demand forecasting.

Keywords: Sentiment Analysis; Demand Forecasting; Machine Learning; Natural Language Processing.

SUMÁRIO

1	INTRODUÇÃO.....	9
1.1	Objetivos.....	11
1.1.1	Objetivo geral.....	11
1.1.2	Objetivos específicos.....	11
1.2	Justificativa.....	12
1.3	Metodologia.....	13
1.4	Estrutura do trabalho.....	14
2	ANÁLISE DE TRABALHOS SIMILARES.....	15
2.1	Previsão da volatilidade do Bitcoin.....	15
2.2	Comparação de modelos para previsões de preço.....	16
2.3	Previsão de vendas de elétricos.....	16
2.4	Análise de sentimento no mercado.....	17
2.5	Preferências hoteleiras via análise sentimental.....	18
2.6	Análise detalhada de preferências hoteleiras.....	19
2.7	Otimização de vendas no varejo.....	20
2.8	Previsão de sentimentos no turismo.....	21
2.9	Considerações gerais do capítulo.....	22
3	DESENVOLVIMENTO.....	22
3.1	Materiais e Ferramentas.....	22
3.1.1	Base de dados utilizada.....	11
3.2	Métodos.....	22
3.2.1	Bibliotecas utilizadas.....	11
3.2.2	Tratamento da base de dados.....	11
3.2.3	Tratamento de valores nulos.....	11
3.2.4	Processamento de Linguagem Natural.....	11
<u>3.2.4.1</u>	<u>Seleção do modelo e configuração do pipeline.....</u>	<u>11</u>
<u>3.2.4.2</u>	<u>Definição e avaliação da amostra.....</u>	<u>11</u>
<u>3.2.4.3</u>	<u>Avaliação de desempenho do modelo.....</u>	<u>11</u>
3.2.5	Análise Exploratória dos Dados.....	11
3.2.6	Normalização e balanceamento da base de dados.....	11
3.2.7	Aplicação da previsão de demanda.....	11
<u>3.2.7.1</u>	<u>XGBoost.....</u>	<u>11</u>

3.2.7.2	<i>Random Forest</i>	11
3.2.7.3	<i>Extra Trees</i>	11
3.3	Conclusões do capítulo.....	22
4	RESULTADOS.....	22
4.1	Métricas de avaliação.....	22
4.2	Matrizes de confusão.....	22
4.3	Importância das variáveis.....	22
5	CONCLUSÃO.....	22
	REFERÊNCIAS.....	23
	APÊNDICE A.....	23

(adicionar lista de figuras, quadros e afins)

1 INTRODUÇÃO

A ciência de dados é um campo interdisciplinar que intersecta áreas como: ciência da computação, estatística e matemática aplicada. Tem como objetivo, a partir da coleta de dados: tratá-los, analisá-los, relacioná-los e, a partir de modelos de inteligência artificial, os quais variam de acordo com o problema proposto e os dados disponíveis, gerar previsões que sejam suficientes para tomadas de decisões nos mais diversos setores. Uma predição baseada em metodologia aplicada pode gerar como resultado uma economia de recursos e uma solução suficientemente eficaz e otimizada (QIANG *et al.* 2019).

Nesse âmbito, a análise de sentimentos (também chamada de mineração de opinião) é uma técnica de processamento de linguagem natural (NLP) que identifica e classifica emoções em textos. No contexto da previsão de demanda, ela possibilita mapear informações subjetivas do consumidor fazendo com que suas satisfações, frustrações e tendências de consumo sejam indicativos mais claros dentro do modelo usado. Atualmente, a análise de sentimentos enfrenta inúmeros desafios para a obtenção de uma precisão eficaz e uma determinação correta da polaridade presente nos sentimentos, tais como a detecção de ambiguidades linguísticas, sarcasmo, expressões culturais, sentimentos mistos, falta de contexto, dados ruidosos, desbalanceados e técnicos, dificultando a precisão e a generalização dos modelos (WANKHADE *et al.* 2022).

Contudo, é inegável que a combinação de processamento de linguagem natural para obtenção de mapeamento de sentimentos, junto a outros modelos de predição baseados em inteligência artificial, pode ajudar a prever as demandas dos consumidores, bem como suas ações (MIRZAALIAN e HALPENNY 2019).

O uso de aprendizado de máquina para prever demandas e o próprio comportamento de áreas da indústria é algo corriqueiro em diversos experimentos detalhados na literatura. Nesse sentido, Azamjon, Sattarov e Cho (2023) destacam que os algoritmos de aprendizado de máquina analisam grandes quantidades de dados históricos em tempo real, identificando padrões e relacionamentos que podem não ser perceptíveis pela análise humana. Além disso, afirmam que os modelos de aprendizado de máquina, como análise de regressão, redes neurais e árvores de

decisão, são hábeis em processar essa multiplicidade de pontos de dados, refinando suas previsões com cada nova informação. Algumas áreas comumente fazem uso de tais técnicas, tais como: Hotelaria (MIRZAALIAN e HALPENNY 2019), Indústria Automotiva (GUAN *et al.* 2022), Mercado de criptomoedas (AZAMJON *et al.* 2023), dentre tantas outras. Em todas, a predição da demanda de recursos é essencial para prever a volatilidade da área de estudo.

O uso de aprendizado de máquina e modelos baseados em inteligência artificial para processar linguagem natural e minerar textos está diretamente relacionado à análise de sentimento que o projeto pretende realizar. Segundo os autores Kejriwal, Garg e Sarin (2022), a análise de sentimentos envolve a utilização de técnicas de mineração de dados, aprendizado de máquina e inteligência artificial para determinar o sentimento de um texto, classificando-o como "positivo", "negativo" ou "neutro". Além disso, eles destacam que a análise de sentimentos é um processo poderoso para analisar dados não estruturados e é fundamental em diversas áreas, como gerenciamento de reputação de marca, análise de mercado, política, avaliação de campanhas de *marketing* e análise de sentimentos financeiros.

Sendo assim, explorar diferentes modelos de classificação de sentimento é de vital importância para transformar textos em dados estruturados, que são fundamentais para o bom funcionamento de modelos de predição. Técnicas como Naive Bayes, Regressão Logística e Redes Neurais (como LSTM e *Transformer*) são usadas para classificar sentimentos em positivo, negativo ou neutro e possibilitam a integração da análise de sentimento a modelos de previsão como séries temporais (ARIMA) ou modelos baseados em aprendizado profundo.

Outro ponto importante na construção de um bom modelo de predição baseado em análise de sentimento encontra-se na coleta de dados em fontes confiáveis. Redes sociais como Twitter, Facebook e Instagram oferecem grande volume de opiniões públicas e frequentemente atualizadas. Outras fontes utilizáveis são *sites* de avaliações. Plataformas como Yelp e Google Reviews contêm avaliações detalhadas dos consumidores. Comentários em *sites* de *e-commerce* também podem revelar padrões de satisfação e insatisfação que influenciam a demanda.

A intercalação da análise de sentimentos com modelos de predição de demanda não é tão expressiva quanto os métodos mais tradicionais que fazem uso exclusivamente de dados estruturados, muito por conta dos desafios acerca do

mapeamento dos sentimentos. Levando isso em consideração, este projeto de pesquisa tem como objetivo explorar e aprofundar os tópicos previamente apresentados, por meio do desenvolvimento de uma aplicação voltada ao processamento de linguagem natural. Esse processo terá como principal resultado a geração de uma variável dependente de sentimento (negativo, positivo ou neutro), a qual será utilizada na previsão de demanda com o apoio de diferentes algoritmos de aprendizado de máquina. Além disso, serão aplicadas métricas de avaliação para comparar a eficiência e o desempenho de cada modelo utilizado. A determinação de uma área específica como hotelaria, varejo, e-commerce, setor financeiro, entre outras possíveis, será feita para validar a aplicação desenvolvida e demonstrar seu potencial impacto.

1.1 Objetivos

A fim de orientar melhor o trabalho de pesquisa, foram definidos um objetivo geral e objetivos específicos, os quais são alcançados ao decorrer do trabalho.

1.1.1 Objetivo geral

O objetivo principal do trabalho é aplicar o aprendizado de máquina para realizar a previsão de demanda em um setor específico da indústria, utilizando uma base de dados que inclua, além de dados estruturados, textos provenientes de avaliações de clientes, os quais serão processados previamente à realização da previsão de demanda para gerar a variável dependente.

1.1.2 Objetivos específicos

- Definir a base de dados para realização dos experimentos necessários para o desenvolvimento da pesquisa.
- Realizar a análise de sentimento nos textos provenientes dos clientes que estão contidos na base de dados por meio de processamento de linguagem natural e gerar a variável classe.
- Obter a previsão de demanda aplicando de 3 a 4 diferentes algoritmos na realização dos experimentos.

- Fazer uma análise comparativa entre as métricas resultantes de cada algoritmo aplicado na base de dados utilizada nos experimentos, tais como **Acurácia, Precisão, F1-Score e Recall.**

1.2 Justificativa

O presente trabalho busca contribuir para o estudo das técnicas de previsão de demanda na indústria por meio da integração de análise de sentimentos a algoritmos de aprendizado de máquina. Enquanto a ciência de dados já oferece uma ampla gama de métodos para trabalhar com dados estruturados, há um espaço crescente para o desenvolvimento de abordagens que tratem dados qualitativos, especialmente no contexto de sentimentos e preferências de consumidores (COSTA *et al.* 2021). Com o aumento da importância das opiniões e *feedbacks* dos consumidores para a estratégia de negócios, a análise de sentimentos tem se mostrado um campo promissor, oferecendo *insights* valiosos que podem ser aplicados para melhor entender as flutuações da demanda e, com isso, otimizar a alocação de recursos (CARVALHO *et al.* 2023)

A combinação do processamento de linguagem natural e de técnicas de aprendizado de máquina para mapeamento de sentimentos representa uma inovação que pode ser aplicada em múltiplos setores da indústria. A partir dessa metodologia, espera-se alcançar um nível de precisão superior nas previsões de demanda, oferecendo uma solução que não apenas contribui para o aprimoramento das práticas de gestão de estoques e recursos, mas também auxilia empresas a responderem de forma mais eficiente às variações de mercado. Este projeto, portanto, visa preencher uma lacuna na literatura ao propor um modelo que busca aprimorar a capacidade de interpretação de dados qualitativos e não estruturados, proporcionando uma abordagem que transforma esses dados em informações práticas e estratégicas para o setor industrial.

Portanto, este trabalho justifica-se pela necessidade de explorar e aplicar técnicas modernas de IA, especialmente no campo da análise de sentimentos, como uma alternativa inovadora para prever demandas. A proposta busca não apenas contribuir academicamente, mas também oferecer uma solução prática e escalável para empresas interessadas em integrar tecnologias avançadas aos seus processos de planejamento e gestão.

1.3 Metodologia

O desenvolvimento deste trabalho está pautado nas etapas apresentadas a seguir.

Pesquisa documental:

A fundamentação teórica é dada por meio do produto do mapeamento sistemático de literatura realizada com base no Protocolo de Kitchenham e Charters (2007). O mapeamento de literatura possibilitou a seleção de oito trabalhos semelhantes e recentes para contribuição de pesquisas na área de análise de sentimento e previsão de demanda. Livros, teses, dissertações, revistas e sites indicados por docentes da área também haverão de ser consultados ao longo do desenvolvimento do projeto.

Recursos Técnicos:

A fim de implementar uma aplicação que seja capaz de realizar os objetivos propostos, alguns recursos devem ser utilizados. A Linguagem Python (versão 3.11.9) é usada para manipulação das bases de dados a fim de realizar análise, tratamento e abstração de um grande volume de dados. A versatilidade dessa linguagem e seu uso já tradicional no ramo da ciência de dados justificam a escolha (MCKINNEY 2022). São utilizadas bibliotecas diversas, como Pandas, Matplotlib, Numpy, Seaborn e Sklearn.

Bases de dados:

As bases de dados são fundamentais para todo o processo. A consulta de bases em *sites* como Kaggle¹, Google Dataset Search² e IBGE (Instituto Brasileiro de Geografia e Estatística)³ determinam potenciais bases que possam viabilizar o projeto de pesquisa. A base Brazilian E-Commerce⁴ será usada.

Modelos de Aprendizado de Máquina:

Diferentes modelos de aprendizado de máquina são testados ao longo da pesquisa. Os modelos apontados como eficientes na pesquisa documental são testados primeiro. São incluídos na pesquisa modelos que tenham uma precisão razoável em comparação com o que há de atual na literatura em pesquisas semelhantes, ou seja, que consigam realizar a previsão de demanda de modo

¹ KAGGLE. Disponível em: <https://www.kaggle.com>.

² GOOGLE DATASET SEARCH. Disponível em: <https://datasetsearch.research.google.com>.

³ INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA. Disponível em: <https://www.ibge.gov.br/>.

⁴ BRAZILIAN E-COMMERCE. Disponível em: <https://www.kaggle.com/code/annastasy/brazilian-e-commerce-eda-nlp-ml/notebook>

satisfatório e útil. Após a aplicação dos modelos será feita uma análise comparativa usando diferentes métricas, como Acurácia, Precisão, F1-Score e Recall.

1.4 Estrutura do trabalho

O trabalho está dividido em cinco capítulos. No primeiro, é introduzido o tema do trabalho, motivações e escopo geral. No segundo, parte da fundamentação teórica que foi utilizada para o desenvolvimento do trabalho é destrinchada e contextualizada à medida que influenciaram o produto final dessa pesquisa. No terceiro, a metodologia do trabalho é explicada, contendo as bases de dados, especificações dos métodos, tecnologias e ferramentas utilizadas. No quarto, é apresentado uma análise dos resultados, os quais contarão com análises comparativas das métricas obtidas nas execuções dos algoritmos, ao passo que no último capítulo há as considerações e conclusões finais do trabalho.

2 ANÁLISE DE TRABALHOS SIMILARES

Para melhor embasar o projeto de pesquisa, foi realizado um mapeamento sistemático de literatura com base no Protocolo de Kitchenham e Charters (2007). Por meio do mapeamento foi possível encontrar 8 trabalhos similares publicados nos últimos anos e que contemplam um bom estado da arte.

2.1 Previsão da volatilidade do Bitcoin

O artigo "*Forecasting Bitcoin Volatility Through On-Chain and Whale-Alert Tweet Analysis Using the Q-Learning Algorithm*" (AZAMJON *et al.* 2023), explora a volatilidade do Bitcoin com o intuito de prever tendências de mercado. A pesquisa combina dados on-chain, que detalham transações na *blockchain* do Bitcoin, com tweets da conta @whale_alert, que notifica sobre transações significativas feitas por grandes detentores de criptomoedas (crypto-whales). Utilizando o algoritmo Q-learning (uma abordagem de aprendizado por reforço), os autores analisam variáveis como volume de transações e atividade na rede para gerar previsões sobre tendências de preço. Os resultados indicam que a integração desses diferentes tipos de dados permite uma previsão mais precisa das flutuações de preço, oferecendo *insights* valiosos para investidores e gestores de risco no mercado de criptomoedas.

O estudo destaca a importância da análise de sentimento, especialmente a partir de plataformas como o Twitter, para prever a demanda e os preços de ativos voláteis como o Bitcoin. A inclusão dos tweets da @whale_alert oferece não apenas dados quantitativos sobre grandes transações, mas também *insights* sobre a percepção pública em torno delas. Dado o impacto das reações sociais no mercado de criptomoedas, essa dimensão torna-se crucial para entender a demanda. Com o uso de algoritmos de aprendizado de máquina, como Q-learning, a pesquisa demonstra que a combinação de dados quantitativos e qualitativos pode aumentar a precisão das previsões. A correlação entre transações de grandes investidores (crypto-whales) e a volatilidade sugere que o sentimento derivado das redes sociais afeta diretamente as expectativas de mercado, abrindo espaço para futuras pesquisas que integrem fontes diversas de dados e técnicas avançadas de análise.

2.2 Comparação de modelos para previsões de preço

O artigo intitulado "*Performance Comparison of LSTM and XGBOOST for Ether Price Prediction from Spam Filtered Tweets*" (SATHIYAPRIYA *et al.* 2023) compara dois modelos de previsão, o LSTM (*Long Short-Term Memory*) e o XGBoost (*Extreme Gradient Boosting*), com o objetivo de prever o preço da criptomoeda Ether a partir de dados de Twitter processados e filtrados para remoção de spam. Os autores destacam a relevância do Twitter como fonte de informações que influenciam a flutuação do preço do Ether.

O estudo propõe uma abordagem inovadora ao integrar aprendizado de máquina e análise de sentimentos para prever variações no preço de criptomoedas, destacando o impacto das opiniões expressas nas redes sociais na demanda e nos preços. A aplicação de um algoritmo robusto de filtragem de spam aprimora a qualidade dos dados analisados, garantindo que apenas informações relevantes sejam consideradas. Os resultados demonstram que a inclusão de dados sentimentais aumenta a precisão das previsões, sugerindo novas possibilidades para pesquisas futuras que considerem múltiplas plataformas sociais e a interconexão entre criptomoedas.

2.3 Previsão de vendas de elétricos

O artigo "*Sale Forecast and Analysis of Public's Attitude of EV Based on Combination of BP and LSTM Network and Decision Tree*" (GUAN *et al.* 2022) apresenta uma investigação abrangente sobre a previsão de vendas de veículos elétricos (EVs) e a análise da atitude do público em relação a essa tecnologia. Utilizando uma combinação de técnicas de aprendizado de máquina, em particular as redes neurais *backpropagation* (BP) e LSTM, juntamente com árvores de decisão, o estudo busca compreender como diferentes variáveis influenciam a aceitação e a compra de EVs.

A pesquisa destaca-se por fornecer *insights* sobre as preferências dos consumidores e as tendências de mercado, especialmente em um contexto de crescente relevância da mobilidade de veículos elétricos.

No que diz respeito à análise de sentimento, o artigo utiliza questionários e entrevistas para captar as emoções e opiniões dos consumidores em relação aos EVs. Por meio da aplicação de métodos de análise de dados, como árvores de

decisão, os autores examinam como aspectos como preço, infraestrutura de carregamento e consciência ambiental afetam a disposição do público em investir. Essa análise não só oferece uma percepção pública, mas também a vincula a padrões de compra subjacentes ao comportamento do consumidor.

A previsão de demanda para veículos elétricos é um dos pontos centrais do estudo, pois modelos preditivos ajudam a identificar tendências futuras e a formular estratégias de marketing eficazes. O artigo discute a eficácia dos modelos LSTM em comparação com abordagens tradicionais, evidenciando como as redes neurais podem captar padrões complexos em dados de vendas. Os resultados indicam que a integração de diferentes métodos pode aprimorar significativamente a precisão das previsões.

Ao incentivar decisões nas políticas de produção e *marketing* na indústria automotiva, esta pesquisa destaca a necessidade de um entendimento mais profundo dos sentimentos e comportamentos dos consumidores, especialmente no contexto de transição para veículos sustentáveis.

2.4 Análise de sentimento no mercado

O artigo "*Predict financial text sentiment: an empirical examination*" (KEJRIWAL *et al.* 2024) explora a importância da análise de sentimento no contexto dos mercados financeiros e a sua aplicação preditiva em relação ao comportamento das ações. Os autores explicam que, além das análises fundamentais e técnicas, a crescente disponibilidade de dados não estruturados, como tweets e notícias financeiras, torna essa abordagem um componente crucial para prever movimentos de preços. O estudo utiliza técnicas de mineração de texto e modelos de *machine learning*, destacando que o classificador *Kernel Support Vector Machine* apresentou a melhor precisão, com 68% na classificação de sentimentos como "positivo", "negativo" ou "neutro".

No âmbito da análise de sentimento, a pesquisa abrange diversas categorias, como a análise de sentimentos fina, a detecção de emoções e a análise baseada em intenções. Essas abordagens são essenciais para entender não apenas como os investidores reagem às informações, mas também para antecipar tendências de mercado. Além disso, essa técnica desempenha um papel fundamental no processo de tomada de decisão dos investidores, ao automatizar a

interpretação de grandes volumes de dados que, de outra forma, seriam difíceis de processar manualmente.

Os resultados do estudo indicam que a análise de sentimentos pode facilitar previsões de demanda, uma vez que o humor do mercado e a percepção pública exercem influência significativa sobre os preços das ações. Ao classificar rapidamente informações financeiras em categorias de sentimento, investidores podem tomar decisões mais informadas e oportunas, reduzindo riscos e aumentando lucros potenciais. O artigo não apenas contribui para o campo da análise financeira, mas também sugere que a integração dessa abordagem de análises de sentimentos com técnicas preditivas pode criar um modelo robusto para a previsão de tendências no mercado financeiro.

2.5 Preferências hoteleiras via análise sentimental

O artigo "*Deriving customer preferences for hotels based on aspect-level sentiment analysis of online reviews*" (ZHANG *et al.* 2021) apresenta uma abordagem inovadora ao analisar preferências dos clientes em relação a hotéis, utilizando técnicas de análise de sentimento em um nível detalhado. Os autores, Jing Zhang, Xingchen Lu e Dian Liu, enfatizam a importância de extrair atributos de hotel a partir de comentários gerados por usuários, o que pode ajudar os gestores a compreender melhor as expectativas dos clientes. A pesquisa aborda o desafio de identificar termos de aspecto implícitos em análises de sentimento, propondo uma metodologia que combina a inserção de co-ocorrência e parsing de dependência, permitindo um entendimento mais profundo das sentenças e seus significados.

A interpretação detalhada dos sentimentos é um dos principais focos do estudo, pois permite que as empresas hoteleiras identifiquem não apenas as percepções gerais, mas também as nuances em relação a várias características do hotel, como localização, serviços e instalações. Os resultados indicam que diferentes tipos de clientes priorizam diferentes atributos, com uma ênfase específica em aspectos como higiene, preço e infraestrutura. Essa abordagem não só melhora a eficácia da extração de sentimentos, mas também oferece *insights* valiosos sobre as áreas que demandam melhorias, frequentemente associadas a feedbacks negativos dos hóspedes.

Além disso, a previsão de demanda pode ser aprimorada por meio dos insights derivados da análise de sentimento. Ao entender quais aspectos os clientes

valorizam mais, os hoteleiros podem ajustar suas ofertas e melhorar a satisfação do cliente, criando uma base mais sólida para a previsão de demanda. A implementação de tais análises permitirá que os hotéis não apenas atendam suas necessidades operacionais, mas também se antecipem a futuras demandas, garantindo uma experiência do cliente mais satisfatória e, consequentemente, aumentando a lealdade e a taxa de retorno dos hóspedes. Dessa forma, este estudo oferece uma contribuição relevante para a interseção entre análise de sentimentos e previsão de demanda, destacando seu papel estratégico na gestão hoteleira..

2.6 Análise detalhada de preferências hoteleiras

O artigo "*Customer preference identification from hotel online reviews: A neural network based fine-grained sentiment analysis*" (BIAN et al. 2022) aborda a importância da análise de sentimentos de avaliações *online* para entender as preferências dos clientes no setor hoteleiro. A pesquisa apresenta um modelo aprimorado de rede neural convolucional, que combina recursos não estruturados e estruturados para melhorar a identificação de pares de aspecto-opinião (AOPs). Esse tipo de análise permite que os hotéis capturem informações detalhadas sobre as opiniões dos clientes em relação a atributos específicos, como qualidade do serviço, preço e instalações, ao invés de se basear apenas em análises de sentimento de nível geral.

A análise precisa dos sentimentos, descrita no estudo, envolve múltiplas etapas, incluindo a extração de elementos sentimentais, identificação de AOPs e cálculo da intensidade do sentimento. Esses processos são fundamentais para classificar e quantificar as preferências do cliente em relação a diferentes atributos do hotel, influenciando diretamente as decisões de reserva e a percepção da qualidade do serviço.

A pesquisa conclui que 11 atributos hoteleiros principais foram destacados pelos clientes e que as preferências variam de acordo com o perfil do hóspede e o objetivo de viagem. Esses resultados ilustram a complexidade do comportamento do consumidor, oferecendo insights valiosos para a personalização de serviços e a formulação de estratégias mais eficazes na gestão hoteleira.

Um comentário sobre os achados do artigo é que eles demonstram como a aplicação de técnicas avançadas de análise de dados, como a análise de sentimentos, pode proporcionar *insights* valiosos para a previsão de demanda no

setor hoteleiro. Ao entender melhor as preferências dos clientes, os gerentes de hotéis podem ajustar suas estratégias de *marketing*, alocar recursos de forma mais eficaz e melhorar a satisfação do cliente. Isso não apenas aumenta a competitividade no setor, mas também pode levar a um aumento na taxa de fidelização e satisfação do cliente a longo prazo.

2.7 Otimização de vendas no varejo

O artigo "*Sales Optimization Solution for Fashion Retail*" (GANHEWA et al. 2021) aborda a implementação de técnicas de aprendizado de máquina (ML) para otimizar as vendas na indústria de varejo de moda, com foco especial em vestuário feminino. A pesquisa reconhece as complexidades do setor, como a volatilidade das tendências de moda e as flutuações na demanda do consumidor, que dificultam a previsão de vendas. Para superar esses desafios, o estudo propõe um sistema que integra três componentes principais: previsão de vendas, segmentação de clientes e análise de demanda. Essa abordagem permite que os varejistas possam gerenciar de forma mais eficiente o estoque e ajustem suas estratégias de marketing e atendam melhor às necessidades dos consumidores. O sistema proposto não só melhora a precisão das previsões, mas também contribui para a maximização das receitas e a redução de perdas associadas a estoques excedentes ou insuficientes.

Uma das abordagens mais interessantes discutidas no artigo é a análise de sentimento, que envolve examinar o *feedback* e as avaliações dos consumidores sobre produtos. Esta análise é fundamental para entender as preferências do cliente, ajudando os varejistas a identificar quais características dos produtos (como cor, estilo ou preço) se destacam nas avaliações positivas. Com isso, as empresas podem ajustar sua oferta de produtos conforme as expectativas dos consumidores, promovendo uma relação mais dinâmica e informativa entre o vendedor e o comprador. A categorização dos *feedbacks* em avaliações positivas e negativas também auxilia na identificação rápida de áreas que necessitam de melhorias.

Ademais, a previsão de demanda, uma parte integral do aplicativo proposto, utiliza algoritmos como o *Extra Trees* para estimar a quantidade de vendas futura com base em dados históricos. Esse processo é fundamental para a gestão eficiente do inventário, ajudando a evitar tanto o excesso quanto a falta de produtos. O uso de métodos de *machine learning* para prever essas demandas oferece uma abordagem

mais precisa de responder às flutuações do mercado, fornecendo aos varejistas ferramentas para maximizar as vendas e melhorar a satisfação do cliente.

Em suma, o artigo oferece uma abordagem inovadora para enfrentar os desafios do varejo de moda, destacando a capacidade de adaptação às necessidades do consumidor e o uso estratégico de dados para prever o comportamento do mercado, promovendo uma gestão mais eficiente e orientada por *insight*.

2.8 Previsão de sentimentos no turismo

O artigo "*Predicting sentiment and rating of tourist reviews using machine learning*" de (PUH E BAGIC 2023) explora o uso de modelos de aprendizado de máquina para analisar sentimentos e prever classificações a partir de avaliações de turistas. Utilizando um conjunto de dados do TripAdvisor, os pesquisadores aplicaram métodos como Naïve Bayes, máquinas de vetor de suporte (SVM), redes neurais convolucionais (CNN), redes de memória de longo e curto prazo (LSTM) e LSTM bidirecionais (BiLSTM). Os resultados demonstraram que os modelos de aprendizado profundo, especialmente o BiLSTM, superaram os algoritmos tradicionais em termos de precisão na classificação de sentimentos em avaliações como positivas, negativas ou neutras, além da previsão de classificações em uma escala de um a cinco estrelas.

A análise de sentimentos desempenha um papel crucial na indústria do turismo, em que as opiniões dos clientes influenciam significativamente as decisões de consumo. O artigo destaca como a capacidade de processar grandes volumes de dados de avaliações geradas por usuários pode fornecer informações valiosas às empresas do setor. Esses *insights* contribuem não apenas para a melhoria das experiências dos turistas, mas também para a adaptação de estratégias de *marketing* e no aprimoramento dos serviços oferecidos, criando uma base de *feedback* que pode orientar melhorias contínuas.

Além disso, o estudo aborda a previsão de demanda com base na interpretação de sentimentos. Ao identificar as preferências e insatisfações dos clientes, os modelos preditivos permitem antecipar tendências de fluxo turísticos e padrões de gastos em determinados destinos. Essa informação é valiosa para gestores e investidores na indústria do turismo, pois possibilita um planejamento

mais eficaz e a alocação adequada de recursos, promovendo a sustentabilidade e crescimento do setor.

Assim, o artigo não apenas contribui para o avanço acadêmico na aplicação de técnicas de aprendizado de máquina no turismo, mas também oferece diretrizes práticas para otimizar a *performance* de serviços em um mercado dinâmico em constante evolução.

2.9 Considerações gerais do capítulo

Em conclusão, os estudos analisados demonstram que a integração de fontes diversas de dados e a utilização de técnicas de aprendizado de máquina (especialmente quando combinadas com a análise de sentimentos) podem proporcionar previsões mais robustas e *insights* estratégicos valiosos. Essa abordagem multidisciplinar não só potencializa a precisão dos modelos preditivos, mas também contribui para a adaptação e inovação das empresas em resposta às rápidas mudanças nas preferências dos consumidores e nas condições de mercado.

3 DESENVOLVIMENTO

Este capítulo apresenta os materiais e métodos utilizados no desenvolvimento deste trabalho. O capítulo encontra-se dividido em três seções, sendo que a seção 3.1 descreve a linguagem utilizada e todas as suas bibliotecas, identificando a sua versão. Descreve também a base de dados e suas principais informações. A seção 3.2 visa explicar o passo a passo da metodologia empregada na análise exploratória, tratamento da base, processamento de linguagem natural e modelos aplicados na base de dados, bem como as bibliotecas utilizadas para que toda metodologia fosse viável. Por fim, a seção 3.3 detalha os resultados do projeto de pesquisa, destacando as métricas de avaliação, o resultado dos objetivos específicos e do objetivo geral.

3.1 Materiais e Ferramentas

Para a implementação deste estudo, utilizou-se o ambiente de desenvolvimento JupyterLab, uma interface web interativa amplamente adotada em projetos de ciência de dados por permitir a integração entre notebooks, código e visualização de dados. A instalação e gerenciamento do JupyterLab foram realizados por meio da distribuição Anaconda, que oferece um conjunto robusto de bibliotecas e ambientes pré-configurados, facilitando o desenvolvimento. A versão utilizada do JupyterLab foi 4.4.1, vigente no momento da realização do trabalho.

Optou-se por essa ferramenta devido ao seu suporte a células interativas, integração com bibliotecas da linguagem Python e capacidade de visualização em tempo real, o que facilita a análise exploratória de dados e a documentação do processo.

Os experimentos e análises foram realizados em notebooks no formato .ipynb, os quais proporcionam uma estrutura sequencial e organizada, favorecendo a compreensão e reprodução dos experimentos.

Para garantir a replicabilidade de execução, recomenda-se a instalação da distribuição Anaconda⁵ e a criação de um ambiente virtual Python na versão 3.10.7. As principais bibliotecas utilizadas foram: Pandas, Numpy, Matplotlib e Seaborn.

⁵ Disponível em: <https://www.anaconda.com/download>. Acesso em: 04/06/2025


3.1.1 Base de dados utilizada

A base de dados utilizada neste trabalho é o *Brazilian E-Commerce Public Dataset by Olist*, disponibilizada gratuitamente na plataforma Kaggle pela empresa brasileira Olist. Esta empresa atua como intermediadora entre pequenos lojistas e grandes marketplaces e *e-commerce*, com o objetivo de ampliar o alcance de vendedores independentes por meio de canais consolidados como Mercado Livre, Amazon, Magalu.

A base de dados foi disponibilizada com a finalidade de fomentar pesquisas acadêmicas e análises sobre o setor de comércio eletrônico no Brasil. Trata-se de uma das poucas bases nacionais com informações reais e estruturadas, abrangendo aspectos como compras, pagamentos, logística, avaliações e comportamento do consumidor. As transações registradas no *dataset* ocorreram entre setembro de 2016 e outubro de 2018, sendo os dados anonimizados pela equipe da própria Olist, que garante a privacidade de clientes e lojistas. A publicação ocorreu na conta oficial da empresa no Kaggle e está licenciada para fins acadêmicos e não comerciais.

A estrutura do dataset consiste em múltiplos arquivos no formato .csv, interrelacionados por meio de chaves primárias e estrangeiras. A Figura 1 apresenta o diagrama com os principais arquivos e suas relações.

Figura 1 - Modelo das bases de dados



Fonte: (colocar e fazer lista de ilustrações)

Cada arquivo representa uma dimensão específica do comércio eletrônico e somente o arquivo `olist_geolocation_dataset.csv` não foi usado, pois a coluna `zip_code_prefix` estava ausente e por isso não foi possível concatená-la às outras bases de dados.

3.2 Métodos

Ao longo do desenvolvimento do projeto foram tomadas decisões baseadas numa metodologia constituída por: análise inicial dos dados, tratamentos iniciais, análise exploratória de dados, processamento de linguagem natural e treinamento de modelos de aprendizado de máquina. Para melhor entendimento de cada etapa da metodologia aplicada, cada ponto foi explicado individualmente neste trabalho escrito.

3.2.1 Bibliotecas utilizadas

O desenvolvimento deste trabalho foi realizado utilizando bibliotecas amplamente consolidadas na área de ciência de dados. A biblioteca Pandas foi empregada para a manipulação de dados tabulares, permitindo a leitura, tratamento e análise eficiente das bases de dados.

Para visualização de dados, utilizaram-se duas bibliotecas complementares: o módulo *matplotlib.pyplot*, voltada à criação de gráficos estáticos, e o *plotly.express*, que possibilita a geração de visualizações interativas, facilitando a interpretação dos resultados por meio de uma análise visual mais dinâmica.

Em relação à análise estatística, foram utilizadas funções da biblioteca *scipy.stats*, com destaque para o cálculo de medidas como assimetria e curtose, que contribuem para a compreensão da distribuição dos dados. As bibliotecas importadas no ambiente JupyterLab estão ilustradas na Figura 2.

(ao longo do desenvolvimento do projeto essa subseção será incrementada com as novas bibliotecas inseridas.)

Figura 2 - Importação das bibliotecas.

```
import pandas as pd
import matplotlib.pyplot as plt
import plotly.express as px
from scipy.stats import skew, kurtosis
#import re
#import nltk
#from nltk.corpus import stopwords
#from nltk.tokenize import word_tokenize
#from nltk.stem import WordNetLemmatizer
```

Fonte: Autoria própria (2025)

3.2.2 Tratamento da base de dados

Inicialmente todas as bases de dados foram importadas no projeto, como é possível visualizar na figura 3.

Figura 3 - Importação das bases de dados.

```
# Carregar os datasets que serão utilizados
orders = pd.read_csv("Data/olist_orders_dataset.csv")
order_items = pd.read_csv("Data/olist_order_items_dataset.csv")
products = pd.read_csv("Data/olist_products_dataset.csv")
reviews = pd.read_csv("Data/olist_order_reviews_dataset.csv")
payments = pd.read_csv("Data/olist_order_payments_dataset.csv")
sellers = pd.read_csv("Data/olist_sellers_dataset.csv")
customer = pd.read_csv("Data/olist_customers_dataset.csv")
geolocation = pd.read_csv("Data/olist_geolocation_dataset.csv")
```

Fonte: Autoria própria (2025)

Após a importação, as tabelas da base de dados foram consolidadas por meio da função *merge*, utilizando como chaves primárias os campos *order_id*, *product_id*, *seller_id* e *customer_id*. Essa etapa possibilitou a construção de uma base única, contendo informações integradas sobre cada pedido, tais como os produtos adquiridos, avaliações dos clientes, formas de pagamento, dados dos vendedores e localização geográfica. Essa consolidação foi essencial para garantir a consistência e a integridade do conjunto de dados utilizado nas análises subsequentes.

Durante o processo de tratamento, diversas colunas foram removidas com o objetivo de otimizar a base para os modelos analíticos e preditivos propostos, evitando redundância e reduzindo o ruído informacional. Inicialmente, foram

descartadas colunas de identificação como *order_id*, *customer_id*, *product_id*, *seller_id*, *review_id* e *customer_unique_id*, por não contribuírem diretamente com os objetivos do estudo, especialmente em relação à previsão de demanda.

Além disso, colunas associadas a etapas intermediárias do processo logístico, como *order_approved_at*, *order_delivered_carrier_date*, *shipping_limit_date*, *order_purchase_timestamp*, *order_delivered_customer_date* e *order_estimated_delivery_date*, também foram excluídas, uma vez que não se relacionam de forma direta ao contexto central da pesquisa. Tais variáveis, embora relevantes para a análise de eficiência logística, não foram consideradas essenciais neste contexto.

Também foram removidas colunas com baixa variabilidade ou pouco poder explicativo, como *product_name_lenght* e *product_description_lengh*. A exclusão se baseou em análises exploratórias que indicaram sua irrelevância estatística para os modelos propostos, uma vez que informações geográficas mais detalhadas poderiam ser extraídas da base de geolocalização, caso necessário.

Além disso, registros duplicados foram eliminados e valores ausentes em colunas-chave, como *review_comment_message* e atributos do produto (peso, dimensões, categoria e quantidade de imagens), foram tratados, visando assegurar a integridade dos dados e a qualidade das análises.

Durante o decorrer do projeto, algumas colunas adicionais foram criadas com o intuito de enriquecer o conjunto de informações disponíveis para análise. Duas colunas temporais derivadas foram geradas: *delivery_time*, representando o tempo real de entrega do pedido (diferença entre a data de entrega e a data da compra), e *delivery_time_estimated*, que indica a diferença entre a data estimada de entrega e a data da compra. Essas variáveis são úteis para avaliar possíveis impactos no sentimento do cliente.

3.2.3 Tratamento de valores nulos.

Ao decorrer da análise exploratória duas colunas específicas apresentaram uma grande quantidade de valores nulos, o que fez emergir a necessidade de estratégias para o tratamento dos valores ausentes. Diferente das outras tratativas já realizadas, onde valores nulos foram excluídos por serem uma fração muito pequena dos registros de suas respectivas colunas, o mesmo não aconteceu nas

colunas “review_comment_title” e “delivery_time”, que apresentaram uma quantidade de valores ausentes elevada.

Foi necessário traçar estratégias a fim de tratar os valores ausentes sem que houvesse a necessidade de desconsiderar uma grande quantidade de registros nos quais eles estavam presentes.

Para o tratamento da coluna “review_comment_title”, que corresponde ao título da avaliação em texto, foi utilizado um algoritmo que identificou as palavras mais recorrentes no registro correspondente da coluna “review_comment_message”, a fim de criar títulos novos nos registros ausentes.

Para o tratamento da coluna “delivery_time” foi aplicada a seguinte metodologia: Atribuiu-se a maior data do status para aqueles registros que são menores que a data máxima de entrega da base de dados. No caso da data prevista ser maior que a data máxima da base, repetiu-se a data estipulada. Dessa forma, traçou-se uma lógica que trata os valores ausentes ao mesmo tempo em que se conserva o bom funcionamento dos modelos a serem aplicados.

3.2.4 Processamento de Linguagem Natural (mostrar exemplos também)

A seguir destacam-se as diferentes etapas que compõem o Processamento de Linguagem Natural presente neste trabalho.

3.2.4.1 Seleção do modelo e configuração do pipeline

O presente trabalho utilizou um *pipeline* de Processamento de Linguagem Natural (PLN) para realizar análise de sentimento em avaliações de clientes. Para isso, recorreu-se ao módulo *pipeline* da biblioteca *Transformers*, que permite a utilização de modelos pré-treinados de classificação de texto de maneira simplificada.

Em seguida, procedeu-se ao carregamento do modelo *twitter-xlm-roberta-base-sentiment-finetuned*⁶, um *XLM-RoBERTa* multilíngue ajustado para detecção de polaridade em mensagens do Twitter. Esse modelo foi encapsulado no *pipeline* de classificação, que reúne tokenização, inferência e pós-processamento, retornando para cada entrada um rótulo (positivo, negativo ou

⁶ Disponível em: <https://huggingface.co/citizenlab/twitter-xlm-roberta-base-sentiment-finetuned>
Acesso em: 17/09/2025

neutro) e uma medida de confiança associada. (vale ressaltar que não houve necessidade de limpar o texto)

3.2.4.2 Definição e avaliação da amostra

Para fins de experimentação e viabilidade computacional, foi selecionada uma amostra aleatória de 380 registros, com semente fixa para garantir reprodutibilidade dos resultados. Sobre esse subconjunto, aplicou-se a função de classificação que envia cada texto ao *pipeline* de sentimento. O classificador retorna, para cada avaliação, o rótulo de sentimento e a pontuação de confiança associada, os quais foram incorporados ao DataFrame em novas colunas: *review_comment_message_sentiment* e *review_comment_message_score*. Por fim, a amostra anotada foi exportada em formato Excel, possibilitando análise posterior e integração com outras etapas do trabalho.

Após a exportação da base de dados contendo a quantidade amostral, foi feita a rotulação manual dos sentimentos de cada texto em “Neutro”, “Positivo” e “Negativo”, para que fossem comparados com a saída do modelo utilizado. O tamanho da amostra foi calculado usando a fórmula clássica de tamanho de amostra (1), a qual pode ser representada pela seguinte fórmula:

$$n = \frac{Z^2 \cdot p \cdot (1 - p)}{E^2} \quad (1)$$

Onde:

- n = tamanho da amostra.
- Z = valor crítico da distribuição normal (para 95% de confiança $Z = 1,96$)
- p = proporção esperada de acertos (adotado 0,5 para máxima variabilidade)
- E = Margem de erro tolerada (0,05)

Dessa forma, obteve-se o seguinte resultado para uma amostra com 95% de confiança e 5% de margem de erro:

$$n = \frac{1.96^2 \cdot 0.5 \cdot 0.5}{0.05^2} \approx 384 \quad (2)$$

Além disso, foi feita a correção para população finita de aproximadamente 36.000 registros, a qual é definida por:

$$n_{ajustado} = \frac{n}{1 + \frac{n-1}{N}} \quad (3)$$

Dessa forma:

$$n_{ajustado} = \frac{384}{1 + \frac{383}{36000}} \approx 380 \quad (4)$$

O que resultou em uma amostra de 380 registros, valor utilizado como base experimental. Além da classificação automática, foi realizada a rotulação manual de cada avaliação em “Neutro”, “Positivo” ou “Negativo”, servindo como referência para avaliação de desempenho do modelo.

3.2.4.3 Avaliação de desempenho do modelo

Os testes de confiança realizados posteriormente, demonstraram não apenas a consistência das predições, mas também a efetividade do modelo no domínio específico de avaliações de comércio eletrônico. A Tabela 1 apresenta os principais indicadores:

Tabela 1 – Métrica de avaliação do classificador de sentimento	
Métrica	Valor
Acurácia	0,7895
Precisão	0,8123
Recall	0,7885
F1-score	0,7558

Fonte: Autoria própria (2025)

A avaliação quantitativa apresentou acurácia de 0,7895, indicando que quase 79% das classificações coincidiram com os rótulos de referência. A precisão

de 0,8123 revelou elevada capacidade de o classificador identificar corretamente as avaliações positivas ou negativas, minimizando falsos positivos. O recall de 0,7885 evidenciou boa cobertura dos casos relevantes, enquanto o F1-score de 0,7558 sintetizou de maneira equilibrada precisão e sensibilidade. Tais evidências, aliadas à análise dos escores de confiança fornecidos pelo *pipeline*, reforçam a robustez e a confiabilidade do método proposto, assegurando sua adequação para aplicações práticas em cenários reais de comércio eletrônico.

Após a validação da amostra, o modelo PLN foi aplicado à base de dados completa. Os rótulos foram mapeados para valores numéricos, sendo: 1 para os valores Positivo, 0 para Neutro e -1 para Negativo. Essa transformação foi necessária para utilização da variável *review_comment_message_sentiment* como alvo dos algoritmos de aprendizado supervisionado.


3.2.5 Análise exploratória dos dados

A análise exploratória teve como objetivo compreender as principais características da base de dados, bem como identificar padrões, tendências e possíveis anomalias que pudessem comprometer ou enriquecer a etapa de modelagem preditiva, sendo desenvolvida de acordo com as etapas a seguir:

- Inspeção inicial: os métodos *.head()* e *.info()* foram utilizados para verificação da estrutura da base, tipos das variáveis e valores ausentes.
- Estatística descritiva: para as variáveis quantitativas, calculou-se a média, mediana, desvio padrão, assimetria (*skewness*) e curtose, com o objetivo de avaliar a distribuição dos dados e a presença de distorções.
- Visualizações gráficas: para apoiar essa etapa, utilizou-se as bibliotecas Matplotlib e plotly.express na construção de gráficos que permitiram explorar a distribuição das notas de avaliação dos clientes, a frequência de pedidos por categoria de produto, e a relação entre formas de pagamento e volume de compras.
- Correlação entre variáveis: construção de matriz de correlação e mapa de calor, os quais auxiliaram na seleção de atributos relevantes para a modelagem.

Essa etapa revelou, por exemplo, predominância de avaliações com nota máxima, maior frequência de pedidos em determinadas categorias e prevalência do


Figura 5 - Histograma dos valores de frete dos pedidos.



Fonte: Autoria própria (2025)

Outra análise importante realizada foi feita através do cálculo do mapa de calor, que esboçou a relação entre as diferentes variáveis numéricas. Sua visualização pode ser feita na figura x.

Figura 6 - Mapa de calor para variáveis numéricas.



Fonte: Autoria própria (2025)

Outros gráficos e análises feitos no processo de análise exploratória podem ser conferidos no repositório *supertecode/tcc*⁷.

3.2.6 Normalização e balanceamento da base de dados

Com o objetivo de preparar os dados para as etapas de modelagem preditiva, realizou-se um processo de normalização e codificação que abrangeu variáveis numéricas, categóricas e temporais. Essa preparação visa garantir que as características possuam escalas comparáveis e que o modelo de aprendizado de máquina não seja influenciado por discrepâncias de magnitude ou por representações não numéricas de atributos qualitativos.

- **Variáveis numéricas:** foi utilizada a técnica de padronização z-score, implementada por meio da classe *StandardScaler* da biblioteca

⁷ Disponível em: <https://github.com/supertecode/tcc>. Acesso em: 30/09/2025

scikit-learn. Foram incluídos atributos como *price*, *freight_value*, *product_photos_qty*, *product_weight_g*, dimensões físicas do produto, além de variáveis relacionadas ao pagamento e à pontuação de comentários. Essa transformação subtrai a média e divide pelo desvio padrão de cada coluna, produzindo distribuições com média zero e variância unitária. Tal procedimento evita que variáveis com amplitudes naturalmente maiores, como preço ou peso, exerçam influência desproporcional no ajuste dos algoritmos de aprendizado.

- **Variáveis categóricas nominais:** como *order_status*, *product_category_name*, *payment_type*, *seller_city*, *seller_state*, *customer_city* e *customer_state*, foram convertidas em valores numéricos por meio do *Label Encoding*. Essa abordagem atribui um número inteiro exclusivo para cada categoria distinta, preservando a informação de pertencimento sem introduzir uma ordem artificial entre as classes. Essa codificação é utilizada quando se planeja utilizar modelos que conseguem lidar internamente com representações ordinais sem atribuir significados indevidos às relações numéricas geradas.
- **Variáveis temporais:** empregou-se a normalização Min–Max, também disponibilizada pela *scikit-learn*. Os campos *delivery_time_real* e *estimated_delivery_time* foram escalonados para um intervalo de 0 a 1, garantindo que a magnitude do tempo de entrega real e do tempo estimado não dominasse os demais atributos e permitindo que essas características fossem interpretadas de forma equilibrada pelos algoritmos de modelagem.
- **Balanceamento da variável-alvo:** aplicação do método SMOTE (*Synthetic Minority Oversampling Technique*), na variável-alvo *review_comment_message_sentiment*. O procedimento, implementado pela função *SMOTE* da biblioteca *imbalanced-learn* com *random_state* igual a 42 para garantir reprodutibilidade, consiste em gerar amostras sintéticas da classe minoritária a partir da interpolação dos seus vizinhos mais próximos no espaço de características. Dessa forma, evita-se a simples duplicação de registros existentes, promovendo maior diversidade

e representatividade das instâncias criadas. No final, obteve-se uma proporção de 33% de registros para cada saída possível.

3.2.7 Aplicação da previsão de demanda

Após a preparação, normalização e balanceamento dos dados, procedeu-se à etapa de modelagem preditiva. O objetivo central desta fase foi construir e avaliar modelos capazes de prever o sentimento das avaliações de clientes a partir de variáveis numéricas, categóricas e temporais já tratadas. Para isso, a variável-alvo *review_comment_message_sentiment* foi extraída do conjunto balanceado, juntamente com a remoção da coluna de pontuação de confiança *review_comment_message_score*, resultando em uma matriz de atributos (X) e um vetor de rótulos (y). Em seguida, os dados foram divididos em conjuntos de treinamento e teste, utilizando a função *train_test_split* com 70 % dos registros para treino e 30 % para avaliação, e *random_state* igual a 42 para assegurar reprodutibilidade. Após a divisão dos dados em conjuntos de teste e treino, foram definidos três diferentes algoritmos a serem utilizados. (explicar brevemente como funciona algoritmos baseados em árvores e anexar figura antes da próxima sessão)

3.2.7.1 XGBoost

O XGBoost (*Extreme Gradient Boosting*) é um algoritmo baseado em árvores de decisão que utiliza o método de *gradient boosting* para combinar múltiplos classificadores fracos em um modelo robusto e altamente preditivo. Ele constrói árvores de forma sequencial, onde cada nova árvore busca corrigir os erros das anteriores, minimizando a função de perda por gradiente.

No presente trabalho, o XGBoost foi configurado para classificação multiclasse, adotando *eval_metric* igual a 'mlogloss' para otimizar a *log-loss*, métrica adequada para problemas com mais de duas classes. Essa abordagem oferece grande capacidade de generalização e costuma apresentar desempenho superior em bases de dados heterogêneas e de alta dimensionalidade.

3.2.7.1 Random Forest

A Random Forest é um ensemble de múltiplas árvores de decisão, cada uma treinada em uma amostra aleatória dos dados (*bagging*). As predições finais

são obtidas por votação majoritária, o que confere ao modelo alta robustez e capacidade de lidar com variáveis categóricas ou numéricas sem necessidade de pré-processamento extensivo.

No experimento, a Random Forest foi implementada com *random_state* igual a 42 para garantir reprodutibilidade e com os parâmetros padrão do *scikit-learn*. A técnica é conhecida por sua resistência ao *overfitting* e por fornecer estimativas de importância das variáveis, permitindo compreender quais atributos mais influenciam as previsões.

3.2.7.1 Extra Trees

O algoritmo Extra Trees (*Extremely Randomized Trees*) é semelhante à Random Forest, mas introduz maior aleatoriedade na escolha dos pontos de divisão das árvores. Em vez de buscar o melhor ponto de corte em cada divisão, o Extra Trees seleciona cortes aleatórios e avalia qual gera a melhor separação, o que reduz a variância do modelo e pode acelerar o treinamento.

No contexto desta pesquisa, o Extra Trees foi escolhido pela sua capacidade de treinar rapidamente e lidar com bases de dados balanceadas de médio porte. Assim como na Random Forest, foi utilizada a implementação padrão do *scikit-learn* com *random_state* igual a 42.

3.3 Conclusões do capítulo

O capítulo de desenvolvimento estabeleceu a fundação metodológica e instrumental para a análise de sentimento e previsão de demanda. A seleção de uma base de dados robusta, contendo avaliações de clientes, foi o ponto de partida para a aplicação de técnicas de Processamento de Linguagem Natural (PLN). A utilização de bibliotecas especializadas permitiu o tratamento e a transformação dos dados textuais em um formato estruturado, essencial para a etapa subsequente de modelagem.

Os métodos empregados, desde o tratamento de valores nulos até a normalização e o balanceamento da base de dados, garantiram a qualidade e a consistência dos dados, minimizando vieses e inconsistências que poderiam comprometer a performance dos algoritmos. A aplicação de técnicas de PLN para a extração de sentimentos foi um passo crucial, convertendo as opiniões subjetivas

dos clientes em uma variável de classe (positivo, negativo ou neutro), que serviu como um indicador valioso para a previsão de demanda.

Por fim, a escolha de algoritmos de aprendizado de máquina como XGBoost, Random Forest e Extra Trees para a previsão de demanda reflete a busca por modelos de alta performance e capacidade de generalização. A análise exploratória dos dados complementou a preparação do dataset, oferecendo insights sobre a distribuição e as correlações entre as variáveis, o que é fundamental para a interpretação dos resultados e para o ajuste fino dos modelos.

Em síntese, o capítulo detalhou o processo de construção de um pipeline de análise de dados, desde a coleta e o pré-processamento até a aplicação de modelos preditivos. As escolhas metodológicas foram pautadas pela necessidade de transformar dados não estruturados em informações estratégicas, demonstrando a viabilidade de integrar a análise de sentimentos em modelos de previsão de demanda para obter uma compreensão mais profunda do comportamento do consumidor e otimizar a tomada de decisão de negócios.

4 RESULTADOS

Após o treinamento fazendo uso dos algoritmos XGBoost, Random Forest e Extra Trees, procedeu-se à avaliação sistemática de seus resultados. A fim de se obter várias perspectivas para os resultados, foram calculadas diferentes métricas de avaliação, geradas matrizes de confusão e o cálculo das importâncias das diferentes variáveis no processo preditivo.

4.1 Métricas de avaliação

Para mensurar a capacidade preditiva dos classificadores, foram calculadas as métricas acurácia, precisão, recall e F1-score, todas com *média macro* para refletir igualmente o desempenho em cada uma das três classes de sentimento. A Tabela 2 mostra um comparativo entre as diferentes métricas de avaliação.


Tabela 2 – Métrica de avaliação dos algoritmos				
	Acurácia	Precisão	Recall	F1-score
XGBoost	0,696	0,686	0,697	0,684
Random Forest	0,705	0,696	0,706	0,689
Extra Trees	0,718	0,71	0,719	0,704

Fonte: Autoria própria (2025)

Observou-se que o modelo Extra Trees apresentou o melhor desempenho em todas as quatro métricas de avaliação, obtendo valores ligeiramente superiores a 0,7. O Random Forest apresentou desempenho inferior, registrando acurácia e recall acima de 0,7, porém com valores de precisão e F1-score levemente inferiores a esse patamar. Por sua vez, o XGBoost obteve os piores resultados, com desempenho abaixo de 0,7 em todas as métricas consideradas.


4.2 Matrizes de confusão

Para cada algoritmo, o código gerou um mapa de calor com a matriz de confusão, permitindo observar a distribuição de acertos e erros entre as classes, comparando valores previstos com os valores reais da base de teste. Os resultados do XGBoost podem ser visualizados na figura :




Fonte: Autoria própria (2025)

Os resultados do Random Forest podem ser visualizados na figura :



Fonte: Autoria própria (2025)

Os resultados do Extra Trees podem ser visualizados na figura :



Fonte: Autoria própria (2025)


Em todos os modelos foi possível visualizar que o número de acertos para previsões de sentimento positivo ou negativo são consideravelmente maiores em comparação ao número de acertos para previsões do sentimento neutro. Enquanto a soma de previsões incorretas para positivos ou negativos são inferiores às respectivas previsões corretas, o mesmo não ocorre para as previsões de sentimento neutro, que são incorretas na maioria dos testes.

4.3 Importância das variáveis

Além das métricas de desempenho, foi realizada uma análise de importância das variáveis (*feature importance*), recurso nativo dos algoritmos baseados em árvores, como XGBoost, Random Forest e Extra Trees. Essa análise tem como objetivo identificar quais atributos do conjunto de dados exercem maior influência nas decisões do modelo, contribuindo para a interpretação e para o entendimento do fenômeno em estudo.


Para cada modelo treinado, utilizou-se a propriedade *feature_importances_* disponibilizada pelas bibliotecas do *scikit-learn* e do XGBoost. Os valores retornados indicam o ganho relativo que cada atributo proporciona na redução da impureza das árvores de decisão. Em seguida, os resultados foram organizados em um DataFrame e classificados em ordem decrescente de importância.

Na figura [x](#) podemos ver que, para o XGBoost, a variável `review_score`, que se trata da nota avaliada pelo cliente ao produto, teve maior influência nas decisões do algoritmo, seguido por variáveis que continham o número da quantidade de fotos no anúncio, número de parcelas na forma de pagamento e o índice sequencial do pagamento para um mesmo pedido, dentre outros de menor relevância. O `review_score` apresentou uma importância muito maior em relação a todas as outras variáveis.




Fonte: Autoria própria (2025)

Na figura [x](#), podemos observar a importância das features para o algoritmo Random Forest. O `review_score` ainda assume maior importância em relação às outras variáveis, seguido de *features* como o tempo de entrega real, tempo de entrega estimado, valor do pagamento total do pedido, dentre outras variáveis de menor relevância. Nesse caso, denota-se uma diferença considerável na influência que cada *feature* exerceu, em comparação ao XGBoost.



Fonte: Autoria própria (2025)

Por fim, na figura **x** podemos observar a importância das features para o algoritmo Extra Trees. Aqui o *review_score* também assume maior importância em relação às outras variáveis, seguido de *features* como o tempo de entrega real, tempo de entrega estimado, cidade do cliente, dentre outras variáveis de menor relevância. Nesse caso, denota-se uma semelhança considerável na influência que cada *feature* exerceu, em comparação ao Random Forest.



Fonte: Autoria própria (2025)

5 CONCLUSÃO

Este trabalho investigou a aplicação do aprendizado de máquina para a previsão de demanda, com um foco inovador na integração da análise de sentimento como um elemento preditivo fundamental. O cerne desta pesquisa reside na criação de uma variável de classe de sentimento, inexistente na base de dados original, a partir da análise de dados textuais. Esta abordagem permitiu a previsão do sentimento do cliente exclusivamente com base nas informações do pedido, estabelecendo um novo paradigma para a compreensão e antecipação do comportamento do consumidor.

A metodologia empregada iniciou-se com uma revisão sistemática da literatura, que solidificou a base teórica para a relevância da análise de sentimento em contextos de previsão. O desenvolvimento prático foi conduzido em um ambiente JupyterLab e Anaconda, utilizando a linguagem Python e bibliotecas como Pandas, Numpy, Matplotlib e Seaborn. Um aspecto crucial da metodologia foi o pré-processamento de linguagem natural, transformando dados textuais brutos em um formato estruturado. Mais significativamente, a análise de sentimento foi aplicada para gerar a variável-alvo *review_comment_message_sentiment*, que posteriormente foi balanceada utilizando a técnica SMOTE (Synthetic Minority Oversampling Technique), garantindo a robustez dos modelos preditivos contra desequilíbrios de classe.

Os resultados obtidos, conforme detalhado na seção 4, demonstram a eficácia da estratégia proposta. A capacidade de inferir o sentimento do cliente a partir de dados de pedido e utilizá-lo como uma variável preditiva não apenas enriqueceu os modelos de previsão de demanda, mas também revelou a influência direta da percepção do cliente nas flutuações de mercado. Esta abordagem híbrida, que transforma dados qualitativos em quantitativos para fins preditivos, oferece uma visão holística e dinâmica do mercado.

As contribuições deste trabalho são multifacetadas. Primeiramente, a pesquisa valida uma metodologia inovadora para a criação de variáveis de classe a partir de dados não estruturados (texto), especificamente o sentimento, para aprimorar a previsão de demanda. Em segundo lugar, oferece *insights* práticos sobre como as empresas podem alavancar informações de pedidos para prever o sentimento do cliente, mesmo na ausência de dados de sentimento explícitos. A

documentação detalhada do processo, desde a engenharia de características baseada em sentimento até a modelagem preditiva, serve como um guia valioso para futuras implementações e pesquisas.

REFERÊNCIAS

- AZAMJON, M.; SATTAROV, O.; CHO, J. Forecasting Bitcoin Volatility Through On-Chain and Whale-Alert Tweet Analysis Using the Q-Learning Algorithm. **IEEE Access**, v. 11, p. 108092-108103, set. 2023.
- BIAN, YIWEN; YE, RONGSHENG; ZHANG, JING; YAN, XIN. Customer preference identification from hotel online reviews: A neural network based fine-grained sentiment analysis. **Computers & Industrial Engineering**, v. 172, p. 108648, set. 2022.
- CARVALHO, RENAN SILVA DE; TONIN, JOYCE MENEZES DA FONSECA; SANCHES, SIMONE LETICIA RAIMUNDINI. Previsibilidade do retorno das ações pela análise do sentimento textual: uma revisão. **Revista de Educação e Pesquisa em Contabilidade (REPeC)**, v. 17, n. 2, p. 140-160, jun. 2023.
- COSTA, JOÃO PAULO VIEIRA; BARROS, ROMULO BALDEZ DE; DANTAS, CAIO CÉSAR SILVA; SOUSA, RAQUEL CRISTINA DE; GOUVEIA, CRISTIANO GONÇALVES NASCIMENTO. Análise de Sentimento para Reviews Apresentados em Vídeos: Modelo de Redes Neurais Treinado em Base de Reviews Escritos. **Brazilian Journal of Technology**, v. 4, n. 1, p. 2-19, jan. 2021.
- GANHEWA, N. B.; ABEYRATNE, S. M. L. B.; CHATHURIKA, G. D. S.; DE SILVA, D.; LUNUGALAGE, D. Sales Optimization Solution for Fashion Retail. In: 3rd International Conference on Advancements in Computing (ICAC). 2021, Malabe. **Anais [...]** Malabe: Sri Lanka Institute of Information Technology, 2021. p. 443-448.
- GUAN ,Q.; MA ,Y.; YANG ,S; Sale Forecast and Analysis of Public's Attitude of EV Base on Combination of BP and LSTM Network and Decision Tree. In: International Conference on Machine Learning and Intelligent Systems Engineering. 2022, Guangzhou. **Anais [...]** Guangzhou: IEEE, 2022. p. 46-51.
- KEJRIWAL, R.; GARG, M.; SARIN, G. Predict financial text sentiment:an empirical examination. **Journal of Management** , v. 21, n.1, p. 44-54, mar. 2022.
- KITCHENHAM, B.; CHARTERS, S. Guidelines for performing systematic literature reviews in software engineering. 2007. **Technical Report**, EBSE Technical Report EBSE-2007-01, Keele University and University of Durham.
- MCKINNEY, WES. **Python for Data Analysis: Data Wrangling with pandas, NumPy, and Jupyter**. 3. ed. Sebastopol: O'Reilly Media, 2022.
- MIRZAALIAN, F.; HALPENNY, E. Social media analytics in hospitality and tourism. **Journal of Hospitality and Tourism Technology**, v. 10, n. 4, p. 764-790, nov. 2019.
- SATHIYAPRIYA, K.; VANKADARA, Sravya; BABU, Kumaresh Suresh; MURALIDHARAN, Mridula. Performance Comparison of LSTM and XGBOOST for Ether Price Prediction from Spam Filtered Tweets. In: International Conference On Intelligent Systems For Communication, Iot And Security (Iciscois). 2023, Coimbatore. **Anais [...]** Coimbatore: IEEE, 2023.

PUH, KARLO; BAGIC, MARINA. Predicting sentiment and rating of tourist reviews using machine learning. **Journal of Hospitality and Tourism Insights**, v. 6, n. 3, p. 1188-1204, fev. 2023.

QIANG, Z.; DAI, F.; LIN, H.; DONG, Y. Research on the Course System of Data Science and Engineering Major. *In*: IEEE INTERNATIONAL CONFERENCE ON COMPUTER SCIENCE AND EDUCATIONAL INFORMATIZATION. 2019, Kunming. **Anais [...]** Kunming: IEEE, 2019. p. 90-93.

WANKHADE, M.; RAO, A.; KULKARNI, C. A survey on sentiment analysis methods, applications, and challenges. **Artificial Intelligence Review**, v. 55, p. 5731-5780, fev. 2022.

ZHANG, JING; LU, XINGCHEN; LIU, DIAN. Deriving customer preferences for hotels based on aspect-level sentiment analysis of online reviews. **Electronic Commerce Research and Applications**, v. 49, p. 101094, set. 2021.

APÊNDICE A

(REFERENCIAR APÊNDICE NO TEXTO)

O arquivo `olist_customers_dataset.csv` contém os dados dos clientes que realizaram ao menos uma compra. Abaixo está a descrição detalhada de cada coluna presente nesse arquivo:

Quadro 1 - Dicionário de dados do arquivo `olist_customers_dataset.csv`

Dicionário de dados do arquivo <code>olist_customers_dataset.csv</code>	
Campo	Descrição
<code>customer_id</code>	Identificador único do cliente gerado pela Olist.
<code>customer_unique_id</code>	Identificador único por pessoa física/jurídica.
<code>customer_zip_code_prefix</code>	Prefixo do código postal (CEP) do cliente (apenas os primeiros 5 dígitos).
<code>customer_city</code>	Nome da cidade do cliente.
<code>customer_state</code>	Unidade Federativa (UF) do cliente (ex: SP, RJ, MG).

O arquivo `list_orders_dataset.csv` contém informações detalhadas sobre os pedidos realizados na plataforma. Abaixo está a descrição detalhada de cada coluna presente nesse arquivo:

Quadro 2 - Dicionário de dados do arquivo `list_orders_dataset.csv`

Dicionário de dados do arquivo <code>list_orders_dataset.csv</code>	
Campo	Descrição
<code>order_id</code>	Identificador único do pedido.
<code>customer_id</code>	Identificador do cliente que realizou o pedido.
<code>order_status</code>	Status atual do pedido.
<code>order_purchase_timestamp</code>	Data e hora em que o pedido foi realizado.
<code>order_approved_at</code>	Data e hora em que o pagamento foi aprovado.

Dicionário de dados do arquivo list_orders_dataset.csv

Campo	Descrição
order_delivered_carrier_date	Data em que o pedido foi entregue à transportadora.
order_delivered_customer_date	Data em que o pedido foi entregue ao cliente.
order_estimated_delivery_date	Data estimada para a entrega do pedido.

O arquivo olist_order_items_dataset.csv detalha os itens individuais que compõem cada pedido realizado na plataforma. Abaixo está a descrição detalhada de cada coluna presente nesse arquivo:

Quadro 3 - Dicionário de dados do arquivo olist_order_items_dataset.csv

Dicionário de dados do arquivo olist_order_items_dataset.csv

Campo	Descrição
order_id	Identificador único do pedido.
order_item_id	Número sequencial que indica a posição do item dentro do pedido
seller_id	Identificador único do vendedor responsável pelo item.
shipping_limit_date	Data limite para o envio do item pelo vendedor.
price	Preço de venda do item (sem incluir o frete).
freight_value	Valor do frete cobrado pelo item.

O arquivo `olist_products_dataset.csv` contém informações detalhadas sobre os produtos vendidos na plataforma. Abaixo está a descrição detalhada de cada coluna presente nesse arquivo:

Quadro 4 - Dicionário de dados do arquivo `olist_products_dataset.csv`

Dicionário de dados do arquivo <code>olist_products_dataset.csv</code>	
Campo	Descrição
<code>product_id</code>	Identificador único do produto.
<code>product_category_name</code>	Nome da categoria do produto em português.
<code>product_name_length</code>	Comprimento do nome do produto (número de caracteres).
<code>product_description_length</code>	Comprimento da descrição do produto (número de caracteres).
<code>product_photos_qty</code>	Quantidade de fotos do produto.
<code>product_weight_g</code>	Peso do produto em gramas.
<code>product_length_cm</code>	Comprimento do produto em centímetros.
<code>product_height_cm</code>	Altura do produto em centímetros.
<code>product_width_cm</code>	Largura do produto em centímetros.

O arquivo `olist_sellers_dataset.csv` contém informações sobre os vendedores que atuam na plataforma. Abaixo está a descrição detalhada de cada coluna presente nesse arquivo:

Quadro 5 - Dicionário de dados do arquivo `olist_sellers_dataset.csv`

Dicionário de dados do arquivo <code>olist_sellers_dataset.csv</code>	
Campo	Descrição
<code>seller_id</code>	Identificador único do vendedor

Dicionário de dados do arquivo olist_sellers_dataset.csv

Campo	Descrição
seller_zip_code_prefix	Prefixo do código postal (CEP) do vendedor (apenas os primeiros 5 dígitos).
seller_city	Nome da cidade do vendedor.
seller_state	Unidade Federativa (UF) do vendedor (ex: SP, RJ, MG).

O arquivo olist_order_reviews_dataset.csv informações sobre as avaliações feitas pelos clientes após a entrega dos pedidos. Abaixo está a descrição detalhada de cada coluna presente nesse arquivo:

Quadro 6 - Dicionário de dados do arquivo olist_order_reviews_dataset.csv
Dicionário de dados do arquivo olist_order_reviews_dataset.csv

Campo	Descrição
review_id	Identificador único da avaliação.
order_id	Identificador do pedido associado à avaliação.
review_score	Nota atribuída pelo cliente ao pedido, variando de 1 a 5.
review_comment_title	Título do comentário da avaliação.
review_comment_message	Texto completo do comentário da avaliação.
review_creation_date	Data em que a avaliação foi criada.
review_answer_timestamp	Data e hora em que a avaliação foi respondida pela empresa, se aplicável.

O arquivo `olist_order_payments_dataset.csv` contém informações detalhadas sobre os pagamentos realizados pelos clientes. Abaixo está a descrição detalhada de cada coluna presente nesse arquivo:

Quadro 7 - Dicionário de dados do arquivo `olist_order_payments_dataset.csv`

Dicionário de dados do arquivo <code>olist_order_payments_dataset.csv</code>	
Campo	Descrição
<code>order_id</code>	Identificador único do pedido.
<code>payment_sequential</code>	Índice sequencial do pagamento para um mesmo pedido.
<code>payment_type</code>	Tipo de pagamento utilizado.
<code>payment_installments</code>	Número de parcelas em que o pagamento foi realizado.
<code>payment_value</code>	Valor do pagamento realizado.